Etwas R am Abend

Standort Köln – 06.12.2017

Norman Markgraf

Inhaltsverzeichnis

1 Die Programmiersprache R

Was ist eigentlich R?

Programmiersprache S:

- Von Bell Labs für Statistik, Simulation, Grafik entwickelt (Becker and Chambers; 1984)
- kommerzielle Implementation: **S-PLUS**

Programmiersprache R:

- Implementation unter GPL (GNU General Public License), offener Quellcode

Vorteile:

- Frei und Offen; Kostenlos
- Numerische Stabilität / Genauigkeit
- Methoden- und Anwendungsvielfalt (Finance, Marketing, HR, Psychologie, ...)
- Leicht erweiterbar durch eigene Routinen, Pakete, DLLs
- Standardisiertes, einfach handhabbares Datenformat (*data.frame*)
- Gut durchdachtes Format zur Anpassung von (Regressions-)Modellen
- Einfache Entwicklung ansprechender Diagramme und interaktiver Apps (z.B. shiny).
- Große und aktive Entwickler*innen Gemeinde mit langer Geschichte: seit 1993; R Konsortium, u. a. IBM, Microsoft, TIPCO, Google, ...
- Neue Methoden der Datenanalyse werden häufig in R entwickelt (auch Big Data, KI, etc.)
- Schnittstellen zu sehr vielen Datenquellen / -banken (auch SocialMedia etc.)

Nachteile:

- Bisher keine echte "Standard"-GUI (aber es gibt ja RStudio)
- Verfügbare Routinen / Pakete manchmal unübersichtlich

Wer nutzt R im echten Leben?

Unternehmen, die „ernsthaft“ Daten analysieren, setzen häufig auf R.

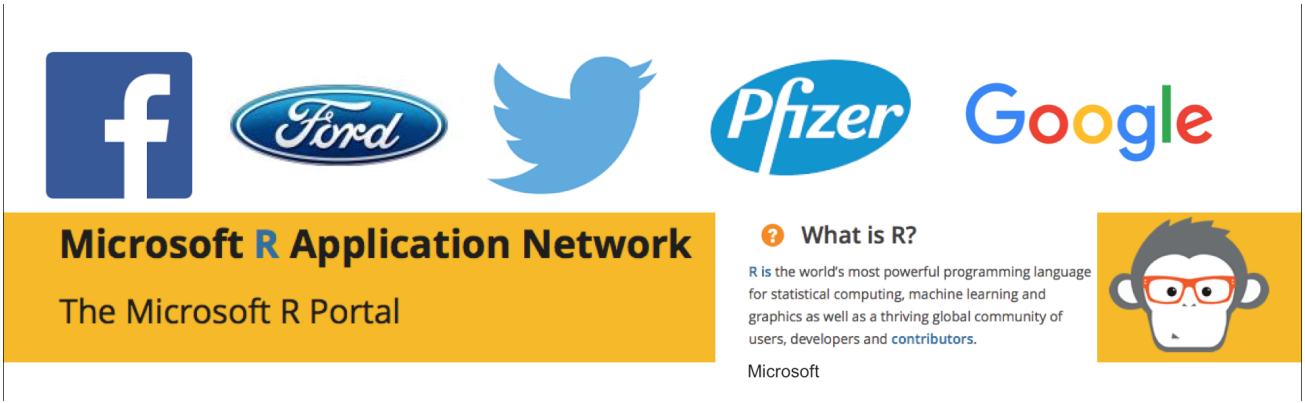

Quelle: http://www.revolutionanalytics.com/companies-using-r

Falls Sie gerne **Werbevideos** ansehen, hier ein Link
https://www.youtube.com/watch?v=TR2bHSJ_eck

Warum R?

> *[. . .] she was also following a wider trend: for many academics [. . .] R is the data-analysis tool of choice.*[1]

Verbreitung z. B.: http://r4stats.com/articles/popularity/

R ist eine weit verbreitete Eintrittskarte in das globale Datenzeitalter!

[1] Tippmann, S.. Programming tools (2015): Adventures with R. A guide to the popular, free statistics and visualization software that gives scientists control of their own data analysis. Nature, 517, S. 109–110. https://doi.org/10.1038%2F517109a

Warum Code?

Politik:

Ich glaube, dass die Fähigkeit zum Programmieren eine der Basisfähigkeiten von jungen Menschen wird, neben Lesen, Schreiben, Rechnen. Die werden nicht wegfallen. Aber Programmieren wird nochmal dazu kommen.[a]

[a] Rede von Bundeskanzlerin Merkel zur Deutsch-Französischen Digitalkonferenz am 13. Dezember 2016

Wirtschaft:

Der Prozess, eine komplexe Aufgabe auf eine Reihe einfacher Anweisungen zu reduzieren - genau darum geht es beim Programmieren -, ist eine Fähigkeit, die in vielen Aspekten des modernen Lebens nützlich ist, nicht nur für professionelle Informatiker und Programmierer.[a]

[a] Facebooks Forschungschef Yann LeCun

Lehre:

Don't fence off students from the computation pool, throw them in! Computing skills are essential to working with data in the 21st century. Given this fact, we feel that to shield students from computing is to ultimately do them a disservice.[a]

[a] Ismay, C, Kim, A (2017): ModernDive

Vorteile Code

- Dokumentation des Vorgehens
- (Einfache) Nachvollziehbarkeit, Wiederholung
- Möglichkeit zur Automatisierung und Übertragung
- “Direkte” Kommunikation mit dem Programm / Computer
- Speziell R: Unzählige Literatur und Hilfe / Tutorials im Internet

Code: mosaic

Wir nutzen das Paket **mosaic**, da es i. d. R. einer einfachen Idee gehorcht:

```
analysiere( y ~    # ggfs. abhängige Variable
              x  # unabhängige Variable(n)
            | z, # ggfs. bedingende (gruppierende) Variable(n)
          Optionen, # ggfs. weitere Optionen
          data = daten ) # Datensatz
```

`analysiere()`: Was soll R tun?

Hinweis für Mac-User: unter macOS: `~`: `alt+n`, `|`: `alt+7`

Zentrale Fragen

1. Was soll der Computer für mich tun?
2. Was muss der Computer dafür wissen?

2 Installation von R und RStudio

Einfach nur R? Oder darf es etwas mehr sein?

Natürlich können Sie **R** als Programmiersprache direkt von der Konsole aus füttern.

Besser ist es aber seine Skripte vorab mit Hilfe eines Texteditors zu schreiben und **R** dieses ausführen zu lassen.

Noch besser ist die Nutzung von Integrierten Entwicklungsumgebung (*IDE*), wie z. B. RStudio

Meine Empfehlung:

- **R** (3.4.3)
  - **R** finden Sie hier: https://cran.rstudio.com oder https://www.r-project.org
  - Aktuell ist die Version 3.4.3
  - **Achtung MAC-Nuzter!!!**: Sie benötigen zusätzlich erst noch XQuartz.
    - XQuartz finden Sie hier: https://www.xquartz.org
- **RStudio Desktop** (akt. Version: 1.1.383)
  - Die aktuelle Version finden Sie hier: https://www.rstudio.com/products/rstudio/download/
  - Nur Linux-Nutzer **RStudio Server** (akt. Version: 1.1.383)

(Und *bitte*, *vergessen* Sie den **R-CmdR**! Wenn schon, dann schauen Sie sich einmal jamovi an!)

R Installation

0. (Mac-User bitte zurerst xquartz installieren)!
1. R (https://www.r-project.org/)
2. RStudio Desktop (https://www.rstudio.com/)
3. Installation von Zusatzpaketen in RStudio:

Tipps für den Installationsprozess:

- Abwarten und bestätigen ;-)
- Kaffee / Tee / Wasser / ... trinken und ruhig bleiben!

Die "Fehlermeldungen" gehören meisst zum Installationsprozess. Wenn etwas gar nicht läuft. Fragen!

```
install.packages("mosaic")
```

Einfach nur R oder darf es etwas mehr sein?

R ist ein eine *komandozeilenorientierte*-Sprache!

```
1+1
```

```
## [1] 2
```

```
1+2*3^4
```

```
## [1] 163
```

```
x <- 1; y <- 2
x+y
```

```
## [1] 3
```

Die (recht schnell) schöne Ergebnisse produziert:

```
x <- seq(-pi,pi,by=0.1)
plot(x, sin(x),  type="l", col="red",
     main="Sinuskurve")
```

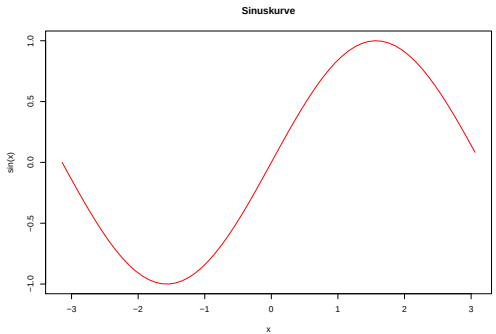

Das wichtigste Pakete und wie man Pakete generell installiert

Im Allgemeinen installiert man ein Paket durch den Befehl:

```
install.packages("<blubber>", dependencies = TRUE)
```

Für einen guten Start sollte man vor allem ein Paket installieren:

Das Paket **mosaic**!

Mehr Informationen zu **mosaic** finden Sie hier:

- Project MOSAIC
- Less Volume, More Creativity – Getting Started with the mosaic Package

Das Paket MOSAIC installieren

Ihr erster R Befehle sollten wie folgt lauten:

```
# Laden des mosaic Pakets:
install.packages("mosaic", dependencies=TRUE)
```

Mit '#' leitet man einen Kommentar ein. Sie müssen aber die Beispiele nicht mit den Kommentaren eintippen, es reicht:

```
install.packages("mosaic", dependencies=TRUE)
```

Bitte bestätigen Sie alle Anfragen und haben Sie etwas Geduld. Es wird eine Menge nachgeladen. Aber nur einmal. Also keine Sorge!

Was Pakete installieren eigentlich bedeutet

Jede R Installation hat einen Vorratsspeicher, in dem die Pakete abgelegt werden. Mit dem Befehl `install.package()` laden Sie dieses Paket aus dem Internet in diesen Vorratsspeicher.

Ähnlich wie Sie ein Buch aus der Bücherrei / Buchhandlung kaufen und ins Regal stellen.

Wenn Sie nun so ein Buch lesen wollen, dann müssen Sie es in die Hand nehmen, aufschlagen und lesen.

In R wird ein Buch aus dem Vorratsspeicher geholt und R angewiesen damit zu arbeiten in dem man den Befehl `library()`nutzt.

Denken Sie daran: Sie kaufen ein Buch nur einmal! Lesen tuen Sie es aber öfter! Demensträchend müssen Sie ein Paket nur *einmal* in den Vorratsspeicher laden, können es aber dann mit `library()` beliebig oft benutzen!

3 Die erste Schritte in R

Die ersten Schritte / R als Taschenrechner

```
# Punkt- vor Strichrechnung
2 * 3 + 2 - 25/5 + 2^3
```

```
## [1] 11
```

```
# Trigometrische Funktionen
cos(pi/2)^2 + sin(pi/2)^2
```

```
## [1] 1
```

```
# Logarithmen & Exponetialfunktion
log(exp(3))
```

```
## [1] 3
```

```
# Unendlich
1/0
```

```
## [1] Inf
```

```
# Not a Number (keine Zahl)
0/0
```

```
## [1] NaN
```

```
# Not Available; ein fehleder Wert
NA
```

```
## [1] NA
```

```
# Vektoren (combine)
c(1, 4:8)
```

```
## [1] 1 4 5 6 7 8
```

```
# Vektor/Liste ohne Inhalt
c()
```

```
## NULL
```

4 Strukturen in R

Variablen

- Variablen in **R** können Skalare, Vektoren, Matrizen oder Objekte beliebiger anderer Klassen sein.
- Man **erzeugt** eine Variable in dem man ihr mit Hilfe von "<-" oder "=" etwas **zuweist**.
- **Variablennamen** können Kombinationen aus Buchstaben, Ziffern, Punkt und Unterstrich sein. Aber **keine Ziffern vorne**!
- **R** ist **case-sensetiv**, es unterscheidet zwischen Groß- und Kleinschreibung!

```
a <- c("FOM", "und", "R", "sind", "SUPER")
A <- 42
a
```

```
## [1] "FOM"   "und"   "R"     "sind"  "SUPER"
```

```
A
```

```
## [1] 42
```

Datentypen

In **R** gibt es die Datentypen

- **numeric** - ganzzahlige (*integer*) oder reelle (*double*) Zahlen
- **character** - Zeichenketten
- **logic** - die logischen Operatoren **TRUE** und **FALSE**
- **list** - Liste von Objekten jeder Art (die wiederum Listen beinhalten können!)

Befehle zum überprüfen der Datentypen:

```
mode(a)
```

```
## [1] "character"
```

```
str(a)
```

```
##  chr [1:5] "FOM" "und" "R" "sind" "SUPER"
```

```
typeof(a)
```

```
## [1] "character"
```

Vektoren

Ein Vektor wird mit dem Befehl **c()** (für *combine*) erzeugt:

```
a <- 5
vektorMitBeliebigemNamen <- c(log(1), a, sqrt(16), 3^2)
vektorMitBeliebigemNamen
```

```
## [1] 0 5 4 9
```

R kann (Rechen-)Operationen auf ganzen Vektoren (elementweise) durchführen:

```
vektorMitBeliebigemNamen * 2
```

```
## [1]  0 10  8 18
```

```
vektorMitBeliebigemNamen + 1
```

```
## [1]  1  6  5 10
```

Sequenzen

Zahlensequenzen werden mit dem Befehl **seq()** erzeugt. Dem Befehl können verschiedene Argumente Übergeben werden:

```
seq(from = 2, to = 9)
```

```
## [1] 2 3 4 5 6 7 8 9
```

```
seq(from = 2, to = 8, by=3)
```

```
## [1] 2 5 8
```

```
seq(from = 2, by = 0.5, length.out = 8)
```

```
## [1] 2.0 2.5 3.0 3.5 4.0 4.5 5.0 5.5
```

```
# 'n:m' entspricht
# seq(from=n, to=m, by=1)
vektor <- 1:4
vektor
```

```
## [1] 1 2 3 4
```

```
# Werte mit rep() wiederholen::
rep("X", times = 5)
```

```
## [1] "X" "X" "X" "X" "X"
```

```
zahlen1 <- c(2, 4)
zahlen1
```

```
## [1] 2 4
```

```
zahlen2 <- rep(zahlen1, times = 2)
zahlen2
```

```
## [1] 2 4 2 4
```

```
rep(zahlen1, each = 2)
```

```
## [1] 2 2 4 4
```

Logische Abfragen

```
people <- c("Klaus", "Max", "Jens", "Dieter")
people
```

```
## [1] "Klaus"  "Max"    "Jens"   "Dieter"
```

```
people == "Max"
```

```
## [1] FALSE  TRUE FALSE FALSE
```

```
vektorMitBeliebigemNamen != 0
```

```
## [1] FALSE  TRUE  TRUE  TRUE
```

```
logischerVektor <- vektorMitBeliebigemNamen <= 3
logischerVektor
```

```
## [1]  TRUE FALSE FALSE FALSE
```

Eigenschaften von Vektoren

names(a) gibt die Namen der Einträge des Vektors a zurück:

```
weight <- c(67, 80, 72, 90)
names(weight)
```

```
## NULL
```

```
weight
```

```
## [1] 67 80 72 90
```

Jetzt geben wir den Werten einen Namen:

```
names(weight) <- people
weight
```

```
##  Klaus    Max   Jens Dieter
##     67     80     72     90
```

Diese Namen werden von **R** sehr oft mit ausgewertet und verwendert:

```
barplot(weight)
```

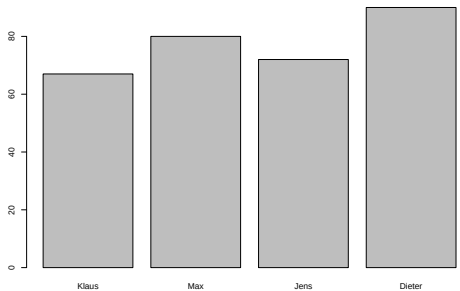

Rechnen mit Vektoren / Datenreihen

In Vektoren speichern wir Datenreihen.

Wichtige Befehle für Vektoren sind - $mean()$, $sd()$, $var()$, $min()$, $max()$, $length()$, $sum()$, $median()$, $IQR()$, $summary()$ - **Zugriff** auf das i-te Element eines Vektors a mit $a[i]$.

```
aVec <- c(1, 2, 4, 9, 16, 25)
mean(aVec)
```

```
## [1] 9.5
```

```
sd(aVec)
```

```
## [1] 9.396808
```

```
var(aVec)
```

```
## [1] 88.3
```

```
min(aVec)
```

```
## [1] 1
```

```
max(aVec)
```

```
## [1] 25
```

```
length(aVec)
```

```
## [1] 6
```

```
sum(aVec)
```

```
## [1] 57
```

Rechnen mit Vektoren

```
median(aVec)
```

```
## [1] 6.5
```

```
IQR(aVec)
```

```
## [1] 11.75
```

```
quantile(aVec)
```

```
##    0%   25%   50%   75%  100%
##  1.00  2.50  6.50 14.25 25.00
```

```
summary(aVec)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    1.00    2.50    6.50    9.50   14.25   25.00
```

```
library(mosaic)
favstats(aVec)
```

```
##  min  Q1 median    Q3 max mean       sd n missing
##    1 2.5    6.5 14.25  25  9.5 9.396808 6       0
```

5 Statistische Funktionen

Varianzen

R berechnet die Varianz von Daten mit Hilfe der (Schätzer-)Formel

$$\frac{1}{n-1} \cdot \sum (x - \bar{x})^2,$$

wie man leicht nachrechnen kann:

```
n <- length(aVec)
var(aVec)
```

```
## [1] 88.3
```

```
# ist das selbe wie
1/(n - 1) * sum((aVec - mean(aVec))^2)
```

```
## [1] 88.3
```

```
# Dagegen ist
1/n * sum((aVec - mean(aVec))^2)
```

```
## [1] 73.58333
```

Die Standardabweichung ist die Quadratwurzel der Varianz:

```
sd(aVec)
```

```
## [1] 9.396808
```

```
sqrt(var(aVec))
```

```
## [1] 9.396808
```

Varianz einer Population

Will man die Varianz und die Standardabweichung mit Hilfe der Formel

$$\frac{1}{n} \cdot \sum (x - \bar{x})^2,$$

berechnen, so muss man in **R** etwas tun:

```
n <- length(aVec)
factor <- (n - 1)/(n)
# Wert
var(aVec)
```

```
## [1] 88.3
```

```
# Korrigierter Wert
factor * var(aVec)
```

```
## [1] 73.58333
```

```
# Zur Probe:
1/n * sum((aVec - mean(aVec))^2)
```

```
## [1] 73.58333
```

```
factorSD <-sqrt((n-1)/n)
# Wert von R:
sd(aVec)
```

```
## [1] 9.396808
```

```
# Korrigierter Wert
factor*sd(aVec)
```

```
## [1] 7.830673
```

```
# Zur Probe
sqrt(1/n * sum( (aVec-mean(aVec))^2 ))
```

```
## [1] 8.578073
```

Rechnen mit Vektoren

```
aVec2 <- rep(2, 6)
aVec
```

```
## [1]  1  2  4  9 16 25
```

```
aVec2
```

```
## [1] 2 2 2 2 2 2
```

```
# Skalarprodukt
aVec %*% aVec2
```

```
##      [,1]
## [1,]  114
```

```
# Komponentenweises *
aVec * aVec2
```

```
## [1]  2  4  8 18 32 50
```

```
aVec3 <- aVec[2:5]
aVec3
```

```
## [1]  2  4  9 16
```

```
aVec3[3]
```

```
## [1] 9
```

```
aVec3[3] <- NA
aVec3
```

```
## [1]  2  4 NA 16
```

```
mean(aVec3)
```

```
## [1] NA
```

```
# NA ignorieren:
mean(aVec3, na.rm = TRUE)
```

```
## [1] 7.333333
```

Dataframes

Merkmale eines Markmalsträgers fasst man gelegendlich zu Tabellen zusammen. In **R** kann man dazu *data frames* nutzen:

```
# Die Datenreihen
Name <- c("Anna", "Beria", "Carlo", "Edda")
Geschlecht <- c("weiblich", "weiblich", "männlich", "weiblich")
Groesse <- c(1.60, 1.68, 1.81, 1.71)
Gewicht <- c(52, 60, 80, 70)
```

Diese Datenreihen kann man wie folgt zu einem Objekt zusammenfassen:

```
# Als Dataframe:
df <- data.frame(
    Name = Name,
    Geschlecht = Geschlecht,
    Groesse = Groesse,
    Gewicht = Gewicht)
#
```

Ausgabe von Dataframes als Tabellen

```
df
```

```
##    Name Geschlecht Groesse Gewicht
## 1  Anna   weiblich    1.60      52
## 2 Beria   weiblich    1.68      60
## 3 Carlo   männlich    1.81      80
## 4  Edda   weiblich    1.71      70
```

In *RMarkdown*-Skripten möchte man gerne eine schönere Ausgabe haben. Dies geht z. B. mit dem Befehl `kable` aus dem Paket `knitr`:

```
library(knitr)
kable(df)
```

Name	Geschlecht	Groesse	Gewicht
Anna	weiblich	1.60	52
Beria	weiblich	1.68	60
Carlo	männlich	1.81	80
Edda	weiblich	1.71	70

Arbeiten mit Dataframes

```r
# Ausgabe der Durchschnittsgröße:
mean(df$Groesse)
```

```
## [1] 1.7
```

```r
# Ausgabe des Durchschnittsgewichts:
mean(df$Gewicht)
```

```
## [1] 65.5
```

```r
library(dplyr)
# Nur die Damen
mean(filter(df, Geschlecht=="weiblich")$Groesse)
```

```
## [1] 1.663333
```

```r
# Nur die Herren
mean(filter(df, Geschlecht=="männlich")$Gewicht)
```

```
## [1] 80
```

Arbeiten mit Dataframes

```r
# BMI der Tabelle hinzufügen:
df <- (mutate(df, BMI = round(Gewicht/Groesse^2,
```

```r
# Nur das Geschlecht und den
# BMI ausgwählen:
df2 <- select(df,
    c(Geschlecht, BMI))
```

.

```r
# Nur das Geschlecht und
# den BMI ausgeben
kable(df2)
```

Geschlecht	BMI
weiblich	20.31
weiblich	21.26
männlich	24.42
weiblich	23.94

```r
# Der Größe nach sortieren (absteigend)
df3 <- arrange(df2, desc(Groesse))
kable(df3)
```

Geschlecht	BMI
männlich	24.42
weiblich	23.94
weiblich	21.26
weiblich	20.31

6 Ein paar Schritte in R

Vorbereitungen

Wir arbeiten mit **mosaic**. Daher laden wir als erstes (immer) das Paket in den Speicher von R. Als zweites setzen wir hier mit `set.seed(2009)` den Zufallszahlengenerator von R auf einen von uns gewählten Startwert; dies dient der Reproduzierbarkeit!

```
library(mosaic)
set.seed(2009)
```

Wir wollen nun den Datensatz "miete03" aus dem Netz laden

- Via **RStudio**: Gehen Sie auf das recht obere Fenster, klicken Sie auf *Environment*, Dann klicken Sie **Import Dataset**. Danach **From Text (readr)** und geben Sie als URL bitte https://raw.githubusercontent.com/NMarkgraf/Etwas-R-zum-Nachmittag/master/Datasets/miete03.asc oder einfacher https://tinyurl.com/yblxykf3 ein drücken Sie auf **Update**. Stellen Sie dann den **Delimiter** auf **Tab** (und warten oder drücken nochmal auf **Update**). Mit **Import** wird dann der Datensatz geladen.
- Via **R** direkt: Man kann auch direkt aus **R** mittels ein paar Zeilen die Daten laden:

```
miete03 <- read.table(file = "https://tinyurl.com/yblxykf3", header = TRUE)
```

Unterschiede der beiden Wege

Falls Sie die Daten via RStudio-Oberfläche geladen haben (oder mittels des im *Code preview*) angegebenen Codes, werden sogenannte `tibbles` statt `data.frames` geladen.

Tibbles sind eine Weiterentwicklung der klassischen `data.frames`. Sie erkennen den Unterschied z. B. in dem Sie sich die ersten Zeilen ansehen.

Bei einem **Tibble** sieht die ersten Zeilen wie folgt aus:

```
## Parsed with column specification:
## cols(
##   nm = col_double(),
##   nmqm = col_double(),
##   wfl = col_integer(),
##   rooms = col_integer(),
##   bj = col_double(),
##   bez = col_integer(),
##   wohngut = col_integer(),
##   wohnbest = col_integer(),
##   ww0 = col_integer(),
##   zh0 = col_integer(),
##   badkach0 = col_integer(),
##   badextra = col_integer(),
##   kueche = col_integer()
```

Bei einem Datenrahmen (`data.frame`) dagegen:

```
miete03 <- read.table(file = "https://tinyurl.com/yblxykf3", header = TRUE)
```

```
head(miete03, 2)
```

```
## # A tibble: 2 x 13
##       nm  nmqm   wfl rooms    bj   bez wohngut wohnbest   ww0   zh0
##    <dbl> <dbl> <int> <int> <dbl> <int>   <int>    <int> <int> <int>
## 1 741.39 10.90    68     2  1918     2       1        0     0     0
## 2 715.82 11.01    65     2  1995     2       1        0     0     0
## # ... with 3 more variables: badkach0 <int>, badextra <int>,
## #   kueche <int>
```

Mit dem Befehl:

```
miete03 <- as.data.frame(miete03)
```

wandeln wir, falls gewünscht, **tibbles** in klassische `data.frames` um.

Was beschreibt der Datensatz?

Zahlreiche deutsche Städte erstellen sogenannte Mietspiegel, um Mietern, Vermietern, Mietberatungsstellen und Sachverständigen eine möglichst objektive Entscheidungshilfe in Mietfragen zur Verfügung zu stellen. Die Mietspiegel werden dabei insbesondere zur Ermittlung der "ortsüblichen Vergleichsmiete" (Nettomiete in Abhängigkeit von Wohnungsgröße, -ausstattung, -alter, etc.) herangezogen. Bei der Erstellung von Mietspiegeln wird aus der Gesamtheit aller in Frage kommenden Wohnungen eine repräsentative Zufallsstichprobe gezogen (im Fall der Stadt München durch Infratest), und die interessierenden Daten werden von Interviewern anhand von Fragebögen ermittelt.

Der vorliegende Datensatz stellt einen Ausschnitt aus dem Mietspiegel München des Jahres 2003 dar und enthält die Daten von 2053 Wohnungen.

Schauen wir uns die Spaltenüberschriften einmal kurz an:

```
names(miete03)
```

```
##  [1] "nm"       "nmqm"     "wfl"      "rooms"    "bj"       "bez"
##  [7] "wohngut"  "wohnbest" "ww0"      "zh0"      "badkach0" "badextra"
## [13] "kueche"
```

Der Befehl `inspect()`

```
inspect(miete03)
```

```
##
## quantitative variables:
##         name   class      min       Q1   median       Q3      max          mean
## 1         nm numeric    77.31   389.95   534.30   700.48  1789.55 5.700930e+02
## 2       nmqm numeric     1.47     6.80     8.47    10.09    20.09 8.393902e+00
## 3        wfl integer    17.00    53.00    67.00    83.00   185.00 6.959523e+01
## 4      rooms integer     1.00     2.00     3.00     3.00     6.00 2.597662e+00
## 5         bj numeric  1918.00  1948.00  1960.00  1973.00  2001.00 1.957983e+03
## 6        bez integer     1.00     5.00    10.00    17.00    25.00 1.126790e+01
## 7    wohngut integer     0.00     0.00     0.00     1.00     1.00 3.911349e-01
## 8   wohnbest integer     0.00     0.00     0.00     0.00     1.00 2.191914e-02
## 9        ww0 integer     0.00     0.00     0.00     0.00     1.00 3.507063e-02
## 10       zh0 integer     0.00     0.00     0.00     0.00     1.00 8.524111e-02
## 11  badkach0 integer     0.00     0.00     0.00     0.00     1.00 1.850950e-01
## 12  badextra integer     0.00     0.00     0.00     0.00     1.00 9.303458e-02
## 13    kueche integer     0.00     0.00     0.00     0.00     1.00 7.306381e-02
##              sd    n missing
## 1   245.4345066 2053       0
## 2     2.4667425 2053       0
## 3    25.1625576 2053       0
## 4     0.9822173 2053       0
```

Quiz: Sind die Daten plausiebel?

Schauen Sie sich die Daten und die Spaltenbezeichner an, sind die von R gewählten Datentypen (numeric und integer) wirklich immer passend?

Falls nein, wo würden Sie gerne warum was ändern?

Anpassen des Datensatzes

```
miete03$badextra <- as.factor(miete03$badextra)    # Extra Bad
miete03$badkach0 <- as.factor(miete03$badkach0)    # Bad gekachelt
miete03$bez <- as.factor(miete03$bez)              #
miete03$kueche <- as.factor(miete03$kueche)        # Küche
miete03$wohnbest <- as.factor(miete03$wohnbest)    #
miete03$wohngut <- as.factor(miete03$wohngut)      #
miete03$ww0 <- as.factor(miete03$ww0)              # Warmwasser
miete03$zh0 <- as.factor(miete03$zh0)              # Zentralheizung
levels(miete03$zh0) <- c("ja", "nein")
miete03$rooms <- as.factor(miete03$rooms)          # Anzahl der Zimmer
```

Häufigkeitstabelle und Balkendiagramme

Mit dem Befehl **tally** können wir *Häufigkeitstabellen* erstellen:

Absolute Häufigkeitstabelle

```
tally( ~ rooms, data=miete03,
       format="count")
```

```
## rooms
##   1   2   3   4   5   6
## 255 715 759 263  47  14
```

Relative Häufigkeitstabelle in Prozent

```
options(digits=2)
tally( ~ rooms, data=miete03,
       format="percent")
```

```
## rooms
##     1     2     3     4     5     6
## 12.42 34.83 36.97 12.81  2.29  0.68
```

Relative Häufigkeitstabelle

```
options(digits=1)
tally( ~ rooms, data=miete03,
       format="proportion")
```

```
## rooms
##     1     2     3     4     5     6
## 0.124 0.348 0.370 0.128 0.023 0.007
```

```
tally( zh0 ~ rooms, data=miete03,
       format="count")
```

```
##       rooms
## zh0     1   2   3   4   5   6
##   ja  246 644 690 244  42  12
##   nein   9  71  69  19   5   2
```

Häufigkeitstabelle und Balkendiagramme

Und mit dem Befehl **bargraph()** erstellen wir ein Balkendiagramm daraus:

```
bargraph(~rooms, data = miete03)
```

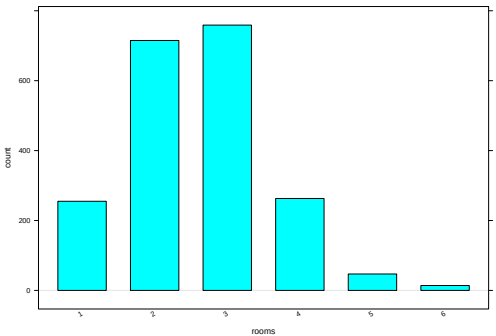


```
bargraph(~rooms, data = miete03, type = '
```

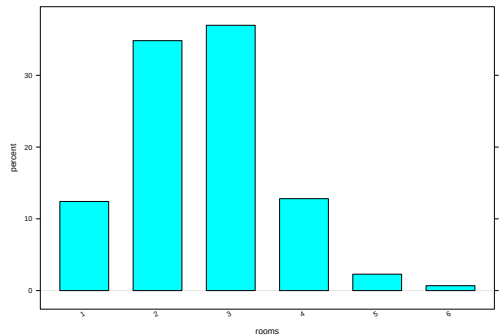


```
#
```

Schönere Diagramme mit ggplot2 und qplot()

Kurzer Exkurs:

Mit dem Paket `ggplot2` und der Funktion `qplot()` würden sich auch schöne Graphiken erstellen lassen!

```
library(ggplot2)
qplot(miete03$rooms, bins=12,
      xlab="Zimmer", ylab="Häufigkeit")
```

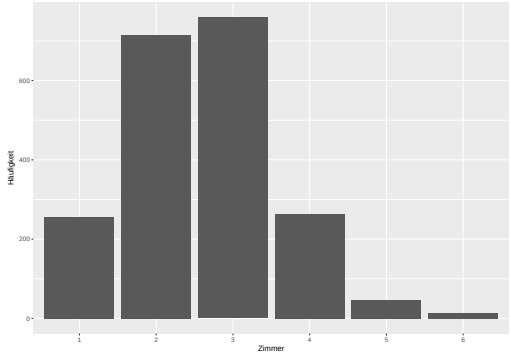


```
library(ggplot2)
ggplot(miete03, aes( x = rooms)) +
    geom_bar() + xlab("Zimmer") +
    ylab("Häufigkeit")
```

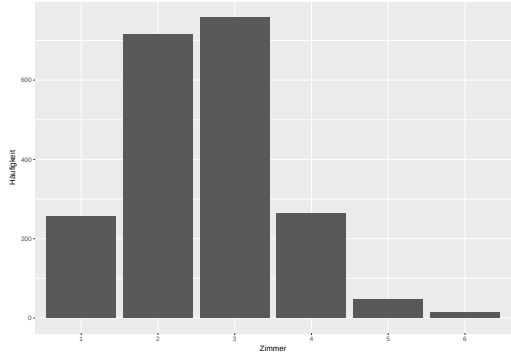

Schönere Graphiken? - Linksammlung:

Wie man mit **ggplot2** noch mehr und noch schönere Grafiken erstellt, können Sie finden bei:

- http://ggplot2.org
- http://docs.ggplot2.org/current/index.html
- http://www.cookbook-r.com/Graphs/
- https://www.datacamp.com/courses/data-visualization-with-ggplot2-1
- http://r4ds.had.co.nz

Die Nettokaltmiete

Automatische Klassenanzahl:

```
histogram( ~ nm, data=miete03)
```

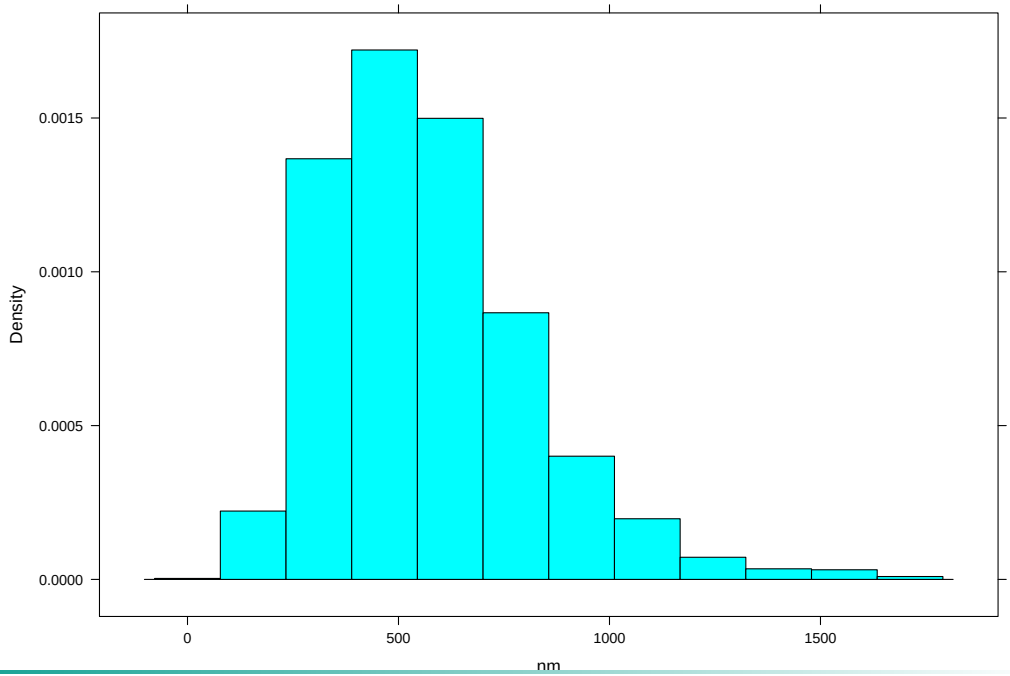

Die Nettokaltmiete

Vorgegebene Klassenanzahl von 8 (wird ungefähr eingehalten):

```
histogram( ~ nm, data=miete03, nint=8)
```

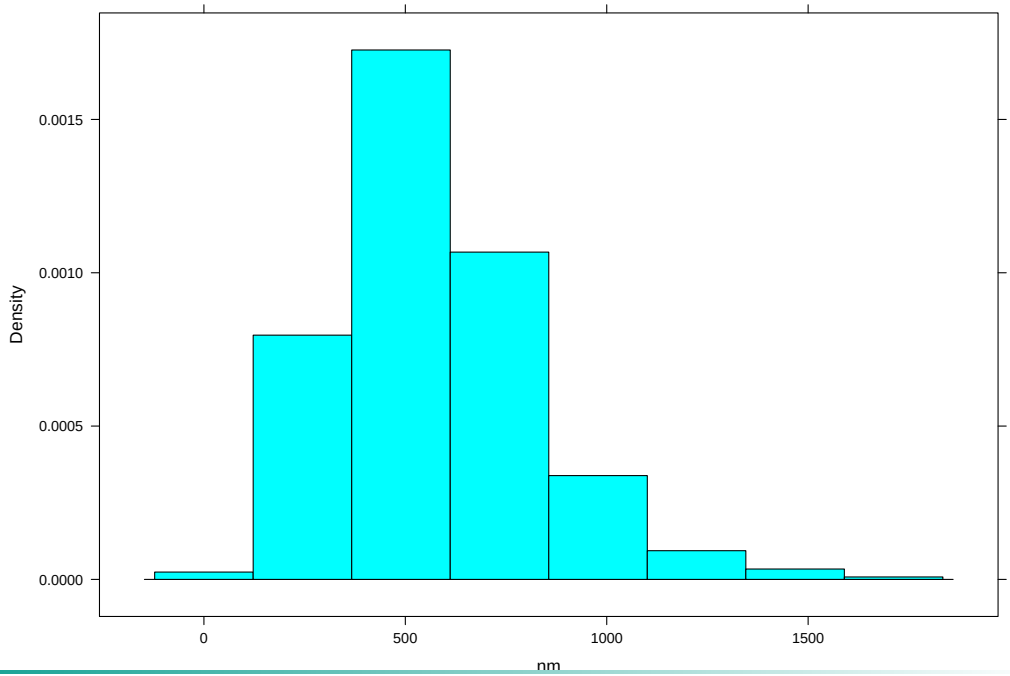

Die Nettokaltmiete

```
histogram( ~ nm, data=miete03, type="percent",
           breaks=c(0, 300, 600, 900, 1200, 1500, 1800),
           main="Nettokaltmiete in München 2003",
           sub="Stichprobe vom Umfang n=2053",
           xlab="Nettokaltmiete in Euro")
```

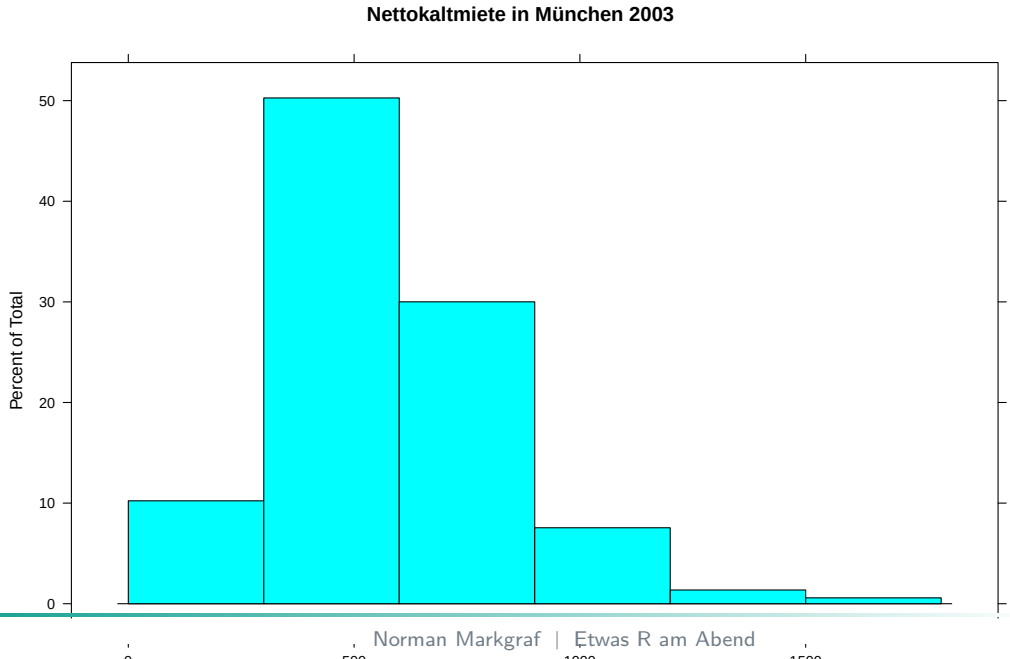

7 Eine kurze Datenanalyse

Vorbereitung

Einlesen der Daten:

Im Folgenden kann man ein paar der Möglichkeiten von **R** finden, wie man sie in Vorlesungen braucht.

Dazu nehmen wir die "tipping" Daten[2] in den Datenrahmen *tips*.

```
# Herunterladen
download.file("https://goo.gl/whKjnl", destfile = "tips.csv")
# Einlesen in R
tips <- read.csv2("tips.csv")

# Alternativ - heruntergeladene Datei einlesen:
# tips <- read.csv2(file.choose())
```

Darüberhinaus nutzen wir einige Befehle aus der Paketsammlung **Mosaic**, welches wir dazu laden

```
library(mosaic) # Hauptsächlich "lattice"
```

[2] Bryant, P. G. and Smith, M (1995) Practical Data Analysis: Case Studies in Business Statistics. Homewood, IL: Richard D. Irwin Publishing

Daten ansehen

Schauen wir uns die Daten etwas an:

```
inspect(tips)
```

```
## categorical variables:
##     name  class levels   n missing                                   distribution
## 1    sex factor      2 244       0 Male (64.3%), Female (35.7%)
## 2 smoker factor      2 244       0 No (61.9%), Yes (38.1%)
## 3    day factor      4 244       0 Sat (35.7%), Sun (31.1%), Thur (25.4%) ...
## 4   time factor      2 244       0 Dinner (72.1%), Lunch (27.9%)
##
## quantitative variables:
##         name   class  min      Q1 median      Q3   max     mean      sd   n missing
## 1 total_bill numeric 3.07 13.3475 17.795 24.1275 50.81 19.78594 8.90241 244       0
## 2        tip numeric 1.00  2.0000  2.900  3.5625 10.00  2.99828 1.38364 244       0
## 3       size integer 1.00  2.0000  2.000  3.0000  6.00  2.56967 0.95110 244       0
```

Tischgröße wirklich quantitativ?

Umwandeln der Tischgröße in eine kategoriale Variable:

```
levels(tips$size)
```

```
## NULL
```

```
tips$size <- as.factor(tips$size)
levels(tips$size)
```

```
## [1] "1" "2" "3" "4" "5" "6"
```

Daten erneut ansehen

Schauen wir uns die Daten erneut an:

```
inspect(tips)
```

```
## categorical variables:
##     name  class levels   n missing                                   distribution
## 1    sex factor      2 244       0 Male (64.3%), Female (35.7%)
## 2 smoker factor      2 244       0 No (61.9%), Yes (38.1%)
## 3    day factor      4 244       0 Sat (35.7%), Sun (31.1%), Thur (25.4%) ...
## 4   time factor      2 244       0 Dinner (72.1%), Lunch (27.9%)
## 5   size factor      6 244       0 2 (63.9%), 3 (15.6%), 4 (15.2%) ...
##
## quantitative variables:
##         name   class  min      Q1 median      Q3   max     mean      sd   n missing
## 1 total_bill numeric 3.07 13.3475 17.795 24.1275 50.81 19.78594 8.90241 244       0
## 2        tip numeric 1.00  2.0000  2.900  3.5625 10.00  2.99828 1.38364 244       0
```

Balkendiagramm bei kategorialen Daten

```
bargraph(~sex, data = tips)
```

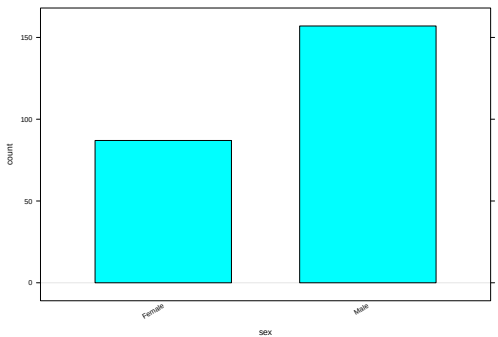


```
bargraph(~size, data = tips)
```

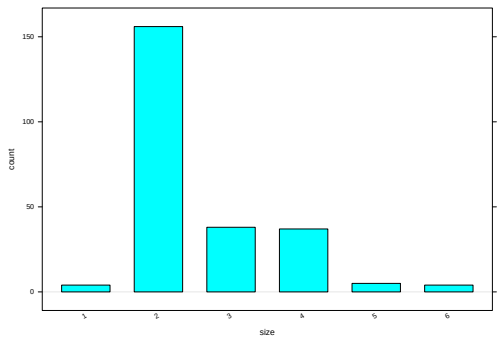

Histogramm bei metrischen Daten

```
histogram(~tip, data = tips)
```

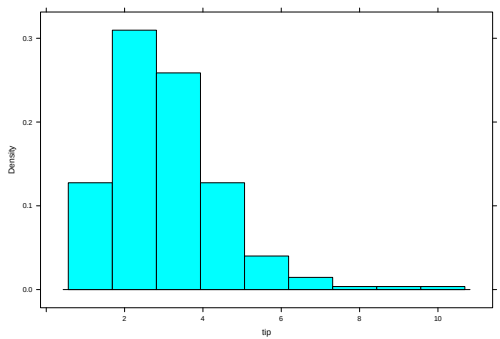


```
histogram(~total_bill, data = tips)
```

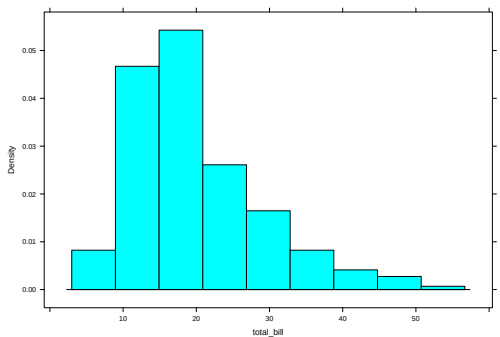

Histogramm bei metrischen Daten, bedingt nach

```
histogram( ~ tip | sex,
          data=tips)
```

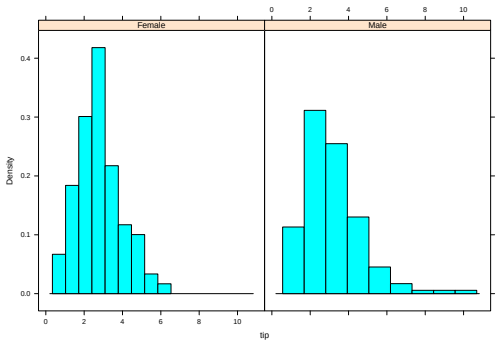


```
histogram( ~ total_bill | size,
          data=tips)
```

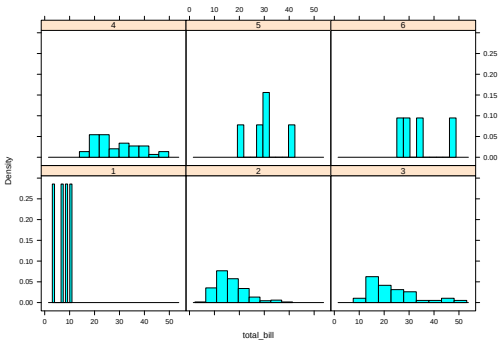

Boxplots bei metrischen Daten

```
bwplot( ~ tip, data=tips)
```

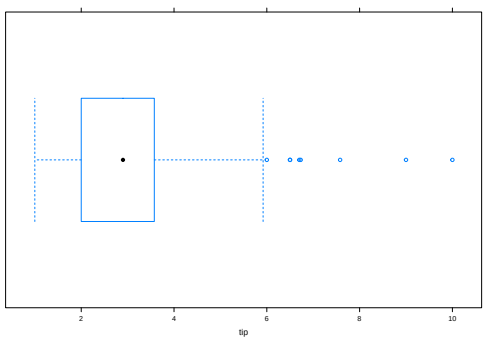


```
bwplot(total_bill ~ size, data=tips)
```

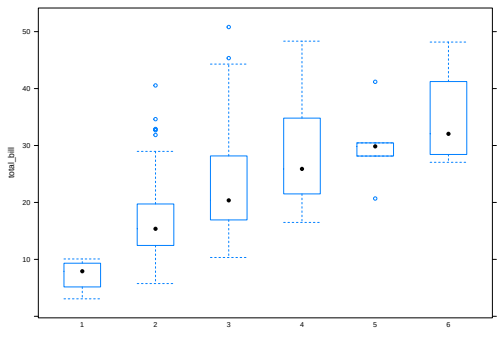

Boxplot mit metrischen Daten für Gruppen, facettiert

```
bwplot(tip ~ sex | smoker, data = tips)
```

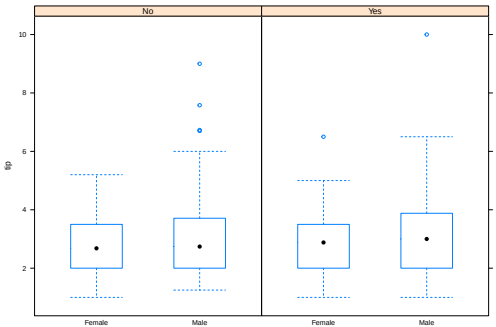


```
#
```

```
bwplot(tip ~ sex | smoker, data = tips, m
    ylab = "Trinkgeld")
```

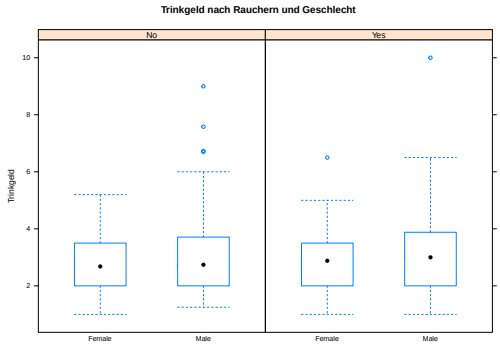

Streudiagramm mit zwei metrischen Variablen

```
xyplot(tip~total_bill, data=tips,
       ylab="Trinkgeld (in USD)", xlab="Rechnungsbetrag (in USD)",
       main="Trinkgelder in Abhängigkeit vom Rechnungsbetrag")
```

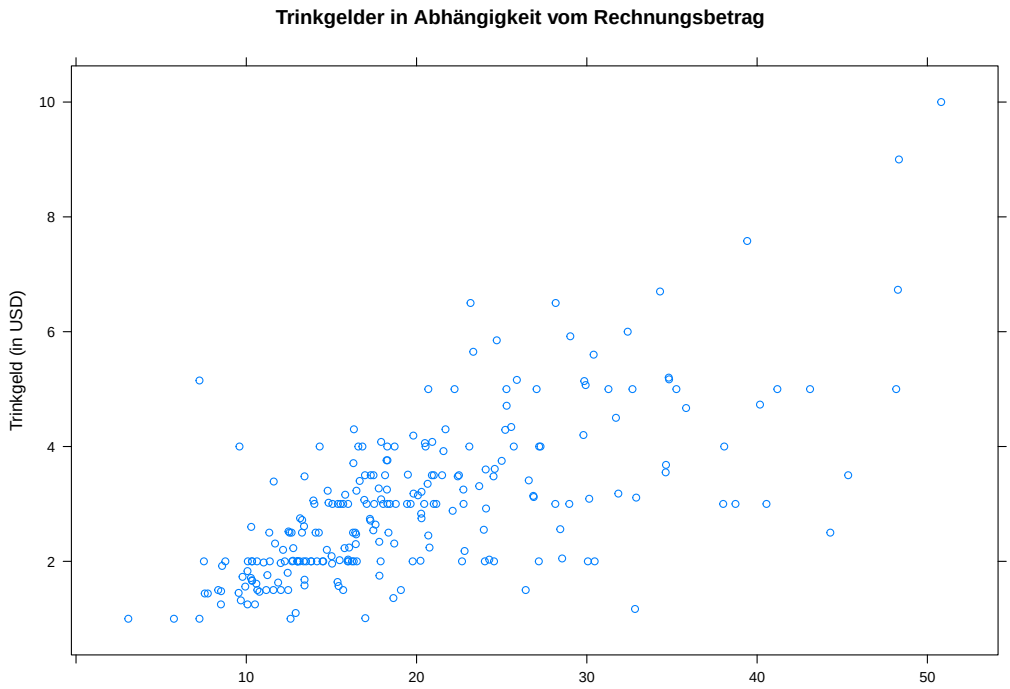

Streudiagramm mit zwei metrischen Variablen

```
xyplot(tip~total_bill, data=tips,
       ylab="Trinkgeld (in USD)", xlab="Rechnungsbetrag (in USD)",
       main="Trinkgelder in Abhängigkeit vom Rechnungsbetrag",
       sub="Daten gruppiert nach dem Geschlecht",
       groups=sex, auto.key = T)
```

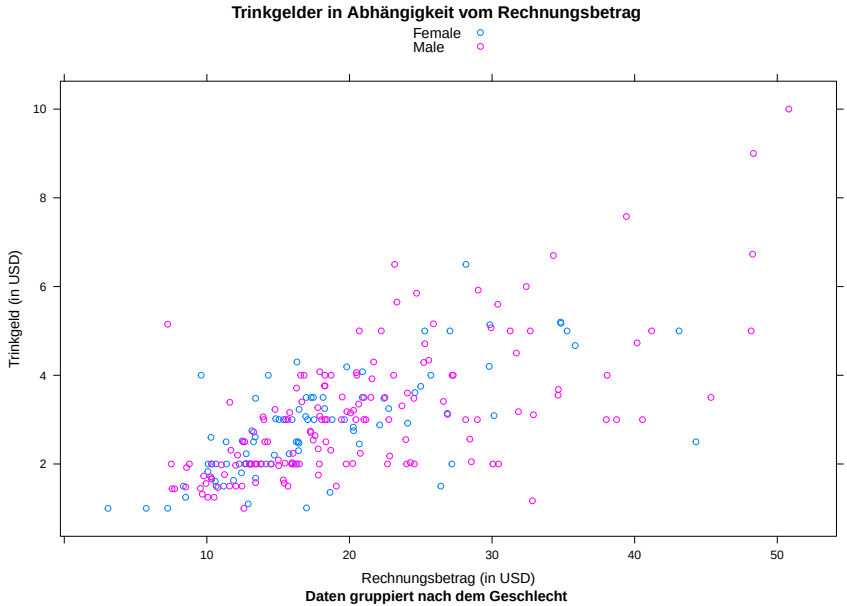

Häufigkeitstabellen zwei kategorialen Variablen

Dazu generieren wir die Häufigkeitstabelle mit dem Befehl *tally* und speichern sie in *tab*

```
tab <- tally(sex ~ smoker, data = tips)
tab
```

```
##         smoker
## sex       No Yes
##   Female 54  33
##   Male   97  60
```

```
library(knitr)
kable(tab,
  col.names=c("N.-Raucher", "Raucher"))
```

	N.-Raucher	Raucher
Female	54	33
Male	97	60

Eine Variante mit relativen Häufigkeiten erhält man mit:

```
tally(sex ~ smoker, data=tips,
      format="proportion")
```

```
##         smoker
## sex           No      Yes
##   Female 0.357616 0.354839
##   Male   0.642384 0.645161
```

```
tally(sex ~ smoker, data=tips,
      format="percent")
```

```
##         smoker
## sex          No     Yes
##   Female 35.7616 35.4839
##   Male   64.2384 64.5161
```

mosaicplot mit zwei kategorialen Variablen

Mit der Tabelle *tab* kann nun ein mosaic plot generiert werden:

```
mosaicplot(tab)
```

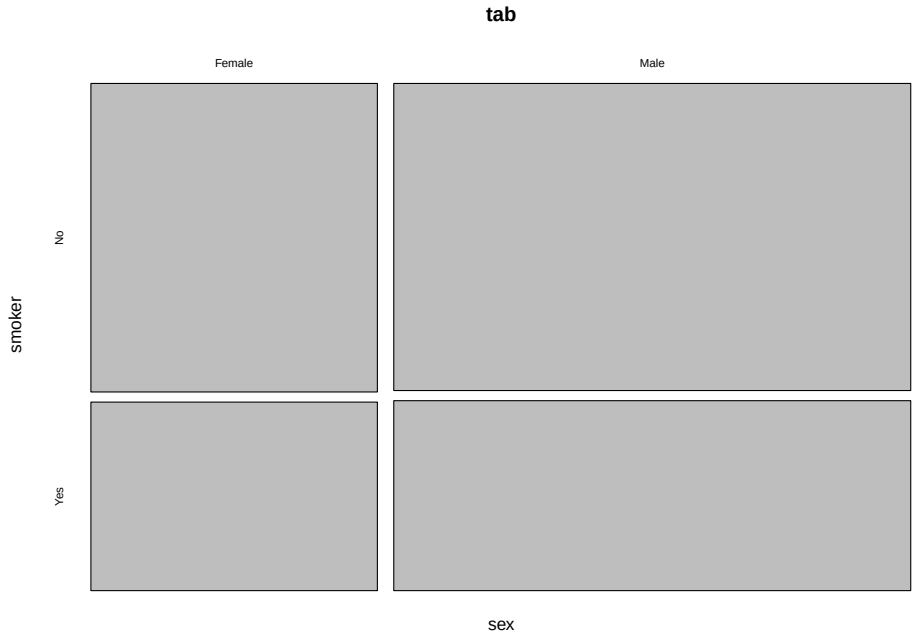

Korrelationsplot mit metrischen Variablen

```
# ggf: install.packages('corrgram', dependencies=T)
library(corrgram)
corrgram(tips)
```

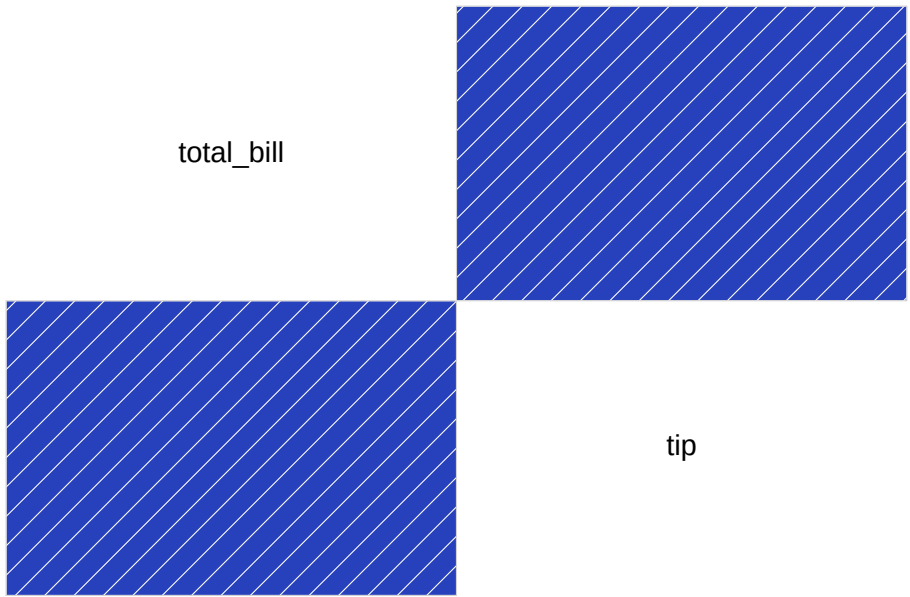

Kennzahlen

Mittelwert

```
mean(tip ~ sex, data = tips)
```

```
##   Female     Male
## 2.83345 3.08962
```

Anstatt *mean* können alle Lageparameter und Streumaße errechnet werden (min, max, median, sd, var):

```
favstats(tip ~ sex, data = tips)
```

```
##      sex min Q1 median   Q3  max    mean      sd   n missing
## 1 Female   1  2   2.75 3.50  6.5 2.83345 1.15949  87       0
## 2   Male   1  2   3.00 3.76 10.0 3.08962 1.48910 157       0
```

Korrelation als Zusammenhangsmaß mit metrischen Variablen

```
cor(tip ~ total_bill, data = tips)
```

```
## [1] 0.675734
```

χ^2-Test

Test der Unabhängigkeit zweier nominalen Variablen mit Hilfe des χ^2-Test:

```
xchisq.test(sex ~ smoker, data=tips)
```

```
##  Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tally(x, data = data)
## X-squared = 0, df = 1, p-value = 1
##
##    54       33
## (53.84)  (33.16)
## [0.00047] [0.00077]
## < 0.022> <-0.028>
##
##    97       60
## (97.16)  (59.84)
## [0.00026] [0.00043]
## <-0.016> < 0.021>
##
## key:
##  observed
##  (expected)
## [contribution to X-squared]
##  <Pearson residual>
```

Nullhypotesten-Tests

t-Test für abhängige Stichproben (Differenzentest)

Variablen müssen beide metrische sein und zwischen beiden Variablen wird eine Differenz gebildet.

Die Forschungsfrage lautet meist:

- V1 unterscheidet sich von V2 (ungerichtet)
- V1>V2 (gerichtet)
- V2>V1 (gerichtet)

```
t.test(~(tip - total_bill), data = tips)
```

```
## ~(tip - total_bill)

##
##  One Sample t-test
##
## data:  tip
## t = -32.65, df = 243, p-value <2e-16
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
##  -17.8006 -15.7748
## sample estimates:
## mean of x
##  -16.7877
```

t-Test für abhängige Stichproben (Differenzentest)

Wenn die Forschungshypothese (Alternativhypothese) gerichtet ist, und V1-V2 < 0 ist, dann wird das Argument alternative="less" hinzugefügt, wenn V1-V2 > 0, dann "greater".

```
t.test(~(tip - total_bill), alternative = "less", data = tips)
```

```
## ~(tip - total_bill)
```

```
##
##  One Sample t-test
##
## data:  tip
## t = -32.65, df = 243, p-value <2e-16
## alternative hypothesis: true mean is less than 0
## 95 percent confidence interval:
##      -Inf -15.9386
## sample estimates:
## mean of x
##  -16.7877
```

Achtung: Bei der Dokumentation von t-Tests ist es wichtig, einseitiges Testen von zweiseitigem Testen zu unterscheiden (einseitig/zweiseitig).

ANOVA (Varianzanalyse)

Bezüglich einer Gruppe (nominale Variable) mit mehr als zwei Levels wird eine metrische Variable getestet.

```
bwplot(tip ~ day, data = tips)
```

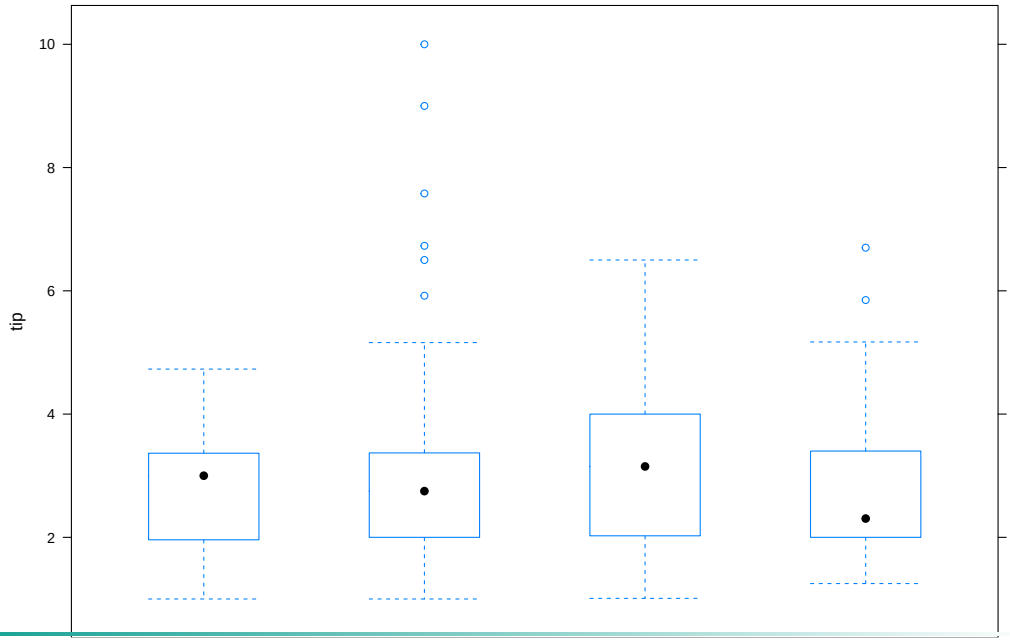

ANOVA (Varianzanalyse)

```
favstats(tip ~ day, data=tips)
```

```
##    day  min     Q1 median     Q3   max    mean      sd  n missing
## 1  Fri 1.00 1.9600  3.000 3.3650  4.73 2.73474 1.01958 19       0
## 2  Sat 1.00 2.0000  2.750 3.3700 10.00 2.99310 1.63101 87       0
## 3  Sun 1.01 2.0375  3.150 4.0000  6.50 3.25513 1.23488 76       0
## 4 Thur 1.25 2.0000  2.305 3.3625  6.70 2.77145 1.24022 62       0
```

Forschungshypothese: Es gibt einen Unterschied beim Trinkgeld bei/zwischen den Tagen.

```
summary(aov(tip ~ day, data=tips))
```

```
##              Df Sum Sq Mean Sq F value Pr(>F)
## day           3     10    3.18    1.67   0.17
## Residuals   240    456    1.90
```

Lineare Einfachregression mit metrischer Variable.

Modellierung einer angängigen Variable (AV) durch eine unabhängige Variable (UV).

```
Mod1 <- lm( tip ~ total_bill, data=tips)
summary(Mod1)
```

```
##
## Call:
## lm(formula = tip ~ total_bill, data = tips)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -3.198 -0.565 -0.097   0.486   3.743
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.92027    0.15973    5.76  2.5e-08 ***
## total_bill   0.10502    0.00736   14.26  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.02 on 242 degrees of freedom
## Multiple R-squared:  0.457,  Adjusted R-squared:  0.454
## F-statistic:  203 on 1 and 242 DF,  p-value: <2e-16
```

Lineare Einfachregression mit kategorialer UV

Achtung: Das nicht ausgegebene Level in der Ausgabe ist das Referenzlevel.

```
Mod2 <- lm(tip ~ day, data = tips)
summary(Mod2)
```

```
##
## Call:
## lm(formula = tip ~ day, data = tips)
##
## Residuals:
##    Min     1Q Median     3Q    Max
## -2.245 -0.993 -0.235  0.538  7.007
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   2.7347     0.3161    8.65  7.5e-16 ***
## daySat        0.2584     0.3489    0.74     0.46
## daySun        0.5204     0.3534    1.47     0.14
## dayThur       0.0367     0.3613    0.10     0.92
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.38 on 240 degrees of freedom
## Multiple R-squared:  0.0205,  Adjusted R-squared:  0.00828
## F-statistic: 1.67 on 3 and 240 DF,  p-value: 0.174
```

Multiple Regression

```
Mod3 <- lm(tip ~ total_bill + sex + smoker + day + time + size, data = tips)
summary(Mod3)
```

```
## Call:
## lm(formula = tip ~ total_bill + sex + smoker + day + time + size,
##     data = tips)
##
## Residuals:
##    Min     1Q Median     3Q    Max
## -2.849 -0.571 -0.103  0.470  4.134
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.86318    0.61168    1.41     0.16
## total_bill   0.09387    0.00975    9.63   <2e-16 ***
## sexMale     -0.03250    0.14350   -0.23     0.82
## smokerYes   -0.07710    0.14830   -0.52     0.60
## daySat      -0.11261    0.31411   -0.36     0.72
## daySun      -0.01248    0.32507   -0.04     0.97
## dayThur     -0.17351    0.40090   -0.43     0.67
## timeLunch    0.08158    0.45290    0.18     0.86
## size2        0.29568    0.53806    0.55     0.58
## size3        0.45547    0.57150    0.80     0.43
## size4        0.69172    0.59090    1.17     0.24
## size5        0.44743    0.73569    0.61     0.54
## size6        1.18049    0.79189    1.49     0.14
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.'
## 0.1 ' ' 1
##
## Residual standard error: 1.03 on 231 degrees of freedom
## Multiple R-squared:  0.472,  Adjusted R-squared:  0.445
## F-statistic: 17.2 on 12 and 231 DF,  p-value: <2e-16
##
```

Der Befehl *step*

Mit dem Befehl *step* führt man eine stufenweise Regressionsanalyse durch, bei der die Variablen nach der Reihenfolge ihrer Wichtigkeit entfernt werden.

```
step(Mod3)
```

```
## Start:  AIC=27.56
## tip ~ total_bill + sex + smoker + day + time + size
##
##              Df Sum of Sq   RSS    AIC
## - day         3      0.65 246.2  22.21
## - size        5      5.02 250.6  22.49
## - time        1      0.03 245.6  25.59
## - sex         1      0.05 245.6  25.61
## - smoker      1      0.29 245.9  25.85
## <none>                    245.6  27.56
## - total_bill  1     98.64 344.2 107.95
##
## Step:  AIC=22.21
## tip ~ total_bill + sex + smoker + time + size
##
##              Df Sum of Sq   RSS    AIC
## - size        5      5.26 251.5  17.36
## - time        1      0.01 246.2  20.21
## - sex         1      0.04 246.3  20.24
## - smoker      1      0.30 246.5  20.51
## <none>                    246.2  22.21
## - total_bill  1     98.74 345.0 102.48
##
## Step:  AIC=17.36
## tip ~ total_bill + sex + smoker + time
##
## - smoker      1      1.27 252.7  16.60
## <none>                    251.5  17.36
## - total_bill  1    204.87 456.3 160.76
##
## Step:  AIC=15.37
## tip ~ total_bill + sex + smoker
##
##              Df Sum of Sq   RSS    AIC
## - sex         1      0.04 251.5  13.41
## - smoker      1      1.27 252.7  14.60
## <none>                    251.5  15.37
## - total_bill  1    210.05 461.5 161.52
##
## Step:  AIC=13.41
## tip ~ total_bill + smoker
##
##              Df Sum of Sq   RSS    AIC
## - smoker      1      1.27 252.8  12.63
## <none>                    251.5  13.41
## - total_bill  1    213.67 465.2 161.45
##
## Step:  AIC=12.63
## tip ~ total_bill
##
##              Df Sum of Sq   RSS    AIC
## <none>                    252.8  12.63
```

8 R intern

Der Arbeitsbereich in R

Der *Arbeitsbereich* (**workspace**) in **R** ist eine Sammlung von Objekten, die aktuell im Speicher vorhanden ist.

Sie können diese Objekte anzeigen mit dem Befehl:

```
ls()
```

Löschen können sie die Objekte mit

```
rm()
```

Pakete

- **R** ist ein **Paketen** organisiert.
- Ein *Paket* ist eine kompakte Zusammenfassung von Code, Hilfeseiten, Daten, Beispielen usw. zu einem bestimmten Themengebiet.
- **R** wächst durch ständig neue Pakete!
- Mit der Installation von **R** haben Sie eine Grundausstattung an wichtigen Paketen, welche Sie nach belieben erweitern können und sollten!
- Die wichtigsten Pakete gibt es beim *C*omprehensive *R* *A*rchive *N*etwork kurz **CRAN**.

Pakete installieren / aktualisieren

Um ein Paket, zum Beispiel **ggplot2**, zu installieren benutz man den Befehl:

```
install.packages("ggplot2")
```

Um gleichzeitig weitere, notwendige Pakete zu installieren nutzt man die Option "dependencies=TRUE":

```
install.packages("ggplot2", dependencies=TRUE)
```

Es gibt aber noch andere Wege! (Direkt in RStudio z.B.!)

Aktualisieren von (allen) Paketen:

```
update.packages()
```

Pakete benutzen

- Mit dem Befehl **library()** (ohne Argument) werden alle bereits installierten Pakete aufgelistet. Nicht alle davon sind automatisch verfügbar, sondern müssen erst geladen werden

```
library(ggplot2)
```

- Liegt das Paket nicht im Standard-library-Verzeichnis, benutzt man die Option **lib.loc=**:

```
library(ggplot2, lib.loc= <Verzeichnis> )
```

- Alternativ können Pakete auch mit **require()** geladen werden. Diese Funktion liefert als Rückgabe die Information ob das Paket verfügbar ist oder nicht.

```
require(ggplot2)
[1] TRUE
```

Verwaltung von Paketen

9 Anhang

Literaturtipps

Wenn Sie sich mehr für **R** interessieren. Ein erster Anlaufpunkt wäre z. B. das Skript "Praxis der Datenanalyse" von

https://sebastiansauer.github.io/Praxis_der_Datenanalyse/

Sauer, S., Gansser, O. (2017). Praxis der Datenanalyse. Skript zum Modul im MSc.-Studiengang "Wirtschaftspsychologie & Consulting" an der FOM. FOM Nürnberg. DOI: 10.5281/zenodo.580649.

Ein gutes Werk in englischer Sprache finden Sie hier:

http://r4ds.had.co.nz/

Garrett Grolemund und Hadley Wickham. R for Data Science.Published by O'Reilly January 2017 First Edition.

Videos zum Thema R und Rcmdr:

Hier finden Sie Videos, die einige Schritte der Datenaufbereitung und deskriptiver / explorativer Datenanalyse erläutern (zumeist mit R-Commander):

- boxplots erstellen https://www.youtube.com/watch?v=9XBjOmA7sNs
- Textdatei öffnen https://www.youtube.com/watch?v=QnM9HBe23Y8
- Öffnen der Datei Polizeistudie https://www.youtube.com/watch?v=SDOoKuj5_7o
- SPSS Datei importieren https://www.youtube.com/watch?v=HS8H_n7Vrm0
- Deskriptive Statistik erstellen https://www.youtube.com/watch?v=qrMpgk-7Wus
- Variablen in Faktoren umwandeln und Balkendiagramm https://www.youtube.com/watch?v=PRR-3kblt8k
- Streudiagramm https://www.youtube.com/watch?v=brE72_0stO0
- Korrelationsmatrix https://www.youtube.com/watch?v=pl92q_S-r8E
- Datenmatrix erstellen https://youtu.be/-EaeBL9J4IE

Die Videos wurden von Frau Prof. Ferreira erstellt.

Copyright / Lizenz / Version

- Datum erstellt: 2017-12-07
- R Version: 3.4.2
- `mosaic` Version: 1.1.0

Diese Präsentation wurde mit **RMarkdown** und ein paar kleinen Helferlein (**NPBT**) erstellt.

Sie finden die (tages-)aktuelle Version, inklusive der Quellen, unter:

https://github.com/NMarkgraf/Etwas-R-am-Abend

Bitte melden Sie Fehler und Verbesserungsvorschläge an: nmarkgraf@hotmail.com

Meinen Dank an Oliver Gansser, Matthias Gehrke, Karsten Lübke, Chistian Schwarz und Sebastian Sauer für Ideen, Tipps und Unterstützung bei der Skripterstellung!